

RAG

Retrieval-Augmented Generation

Como LLMs podem acessar conhecimento externo em tempo real sem retreinamento?

Integrantes do Grupo



Felipe Guerzoni Martins Flôres Maia



Felipe Rivetti Mizher



João Gabriel Polonio Teixeira



Marcos Paulo Miranda Pereira



Matheus Felipe Cavalcanti Xavier

Contexto: Inteligência Artificial

Inteligência Artificial (IA) é a área da computação que ensina máquinas a realizarem tarefas que normalmente exigiriam inteligência humana — como entender texto, reconhecer imagens e responder perguntas.



Machine Learning

Sistemas que aprendem padrões a partir de dados, sem serem explicitamente programados para cada tarefa.



Redes Neurais

Arquiteturas inspiradas no cérebro humano, compostas por camadas de neurônios artificiais que processam informação.



LLMs

Modelos de linguagem grandes (a base tecnológica do RAG.)

O que é um LLM?



Pense assim:

Um LLM é como um estudante que leu bilhões de livros, artigos e sites da internet. Ele aprendeu padrões da linguagem humana e consegue completar frases, responder perguntas e até escrever código — mas só com o que aprendeu até a data em que parou de estudar.



Treinado em texto

Ingere centenas de bilhões de palavras: livros, Wikipedia, código, fóruns, artigos científicos...



Prevê o próximo token

Tecnicamente, aprende a prever qual palavra/token vem a seguir — e dessa tarefa simples emergem capacidades incríveis.



Exemplos reais

ChatGPT (GPT-4), Google Gemini, Meta LLaMA, Anthropic Claude — todos são LLMs com bilhões de parâmetros.

O Problema das Alucinações



"Alucinação" é quando um LLM inventa informações com total confiança que são completamente falsas.

Exemplo Real

Pergunta: "Cite 3 artigos sobre IA publicados em 2023."

LLM responde: "Silva et al. (2023), Costa & Lima (2023), Ferreira (2023)"

Problema: Esses artigos não existem. O modelo inventou autores, títulos e journals plausíveis.


Por que acontece?

- LLMs não têm acesso à internet por padrão
- Só sabem o que estava no treinamento
- Quando não sabem, "completam o padrão" — mesmo com dados inventados
- Não sabem distinguir o que "sabem" do que "imaginam"

Embeddings: Como Máquinas Entendem Significado

Um embedding é a tradução de texto em números (vetores). Textos com significados parecidos ficam "próximos" nesse espaço numérico — como pontos num mapa.

Analogia Visual



← próximos = similar distantes = diferente →

Por que importa para o RAG?

- Documentos são convertidos em embeddings e armazenados
- A pergunta do usuário também vira um embedding
- O sistema busca os documentos com vetores mais próximos
- = **Busca por significado, não por palavras exatas**

P A R T E 2

RAG — O que é e como funciona

Agora que entendemos LLMs e alucinações, vamos ver como o RAG resolve esses problemas.



RAG = Retrieval-Augmented Generation

Técnica que combina um LLM com uma base de documentos externa: antes de responder, o modelo busca informações relevantes e as usa como contexto.



Analogia do Professor

Imagine um professor que, antes de responder sua dúvida, consulta uma biblioteca específica de materiais atualizados.

Ele não inventa — ele lê os documentos e formula a resposta baseado neles.

Esse é o RAG: o LLM com acesso a uma biblioteca personalizada.

LLM Comum vs RAG

	LLM Comum	RAG
Fonte	Treinamento	Treinamento + Docs
Atualização	Data de corte	Tempo real
Alucinação	Alta	Reduzida
Documentos próprios	Não	Sim

Como o RAG Funciona — Passo a Passo

01

**Pergunta**

Usuário faz uma pergunta ao sistema.

02

**Retrieval**

Sistema busca documentos relevantes na base vetorial.

03

**Contexto**

Trechos relevantes são concatenados ao prompt.

04

**Geração**

LLM gera resposta fundamentada nos documentos.



O modelo nunca vê os documentos inteiros — apenas os trechos mais semanticamente próximos da pergunta.



Fase 1 — Indexação (offline)

- 1 Documentos são carregados (PDFs, .txt, bancos de dados...)
- 2 Divididos em chunks (pedaços menores)
- 3 Cada chunk é convertido em embedding pelo modelo de embeddings
- 4 Embeddings são armazenados em um Vector Store (banco vetorial)



Fase 2 — Consulta (online)

- 1 Pergunta do usuário é convertida em embedding
- 2 Busca semântica encontra os K chunks mais próximos
- 3 Chunks + pergunta formam o prompt final
- 4 LLM gera a resposta final com base nesse contexto

Por que RAG é Relevante Hoje?

~40%

das empresas Fortune 500
já adotam RAG em
produtos de IA

Fonte: Gartner, 2024



Reduz alucinações

Respostas ancoradas em documentos reais diminuem drasticamente erros factuais.



Custo muito menor

Fine-tuning custa caro e leva semanas. Com RAG, basta atualizar os documentos.



Dados privados seguros

Os documentos ficam na sua infraestrutura — o modelo apenas os consulta, sem memorizar.



Qualquer domínio

Jurídico, médico, financeiro, educacional — onde há documentos, RAG funciona.

Aplicações Práticas no Mundo Real

Saúde



Chatbot médico que consulta protocolos clínicos atualizados antes de sugerir condutas.

Corporativo



Assistente de RH que responde dúvidas de funcionários consultando manuais e políticas internas.

Educação



Tutor virtual que responde dúvidas dos alunos baseado no material didático específico da disciplina.

Desenvolvimento



Assistente de código que consulta a documentação interna da empresa para sugerir padrões corretos.

Caso de Uso

Empresa com centenas de manuais técnicos internos. Funcionários precisam de respostas rápidas.

1. Usuário pergunta:

"Como resetar minha senha no sistema interno?"

2. RAG busca e recupera:

Trecho do Manual de TI:
"Acesse portal.empresa.com/reset e siga os passos 1-3..."

3. LLM responde:

"Para resetar sua senha, acesse portal.empresa.com/reset e siga os passos 1, 2 e 3..."

Limitações do RAG

Qualidade dos documentos



Se a base de documentos estiver desatualizada ou incorreta, as respostas também estarão. Garbage in, garbage out.

Custo de infraestrutura



Manter um vector store atualizado, fazer chunking e embedding de documentos exige processamento e custo.

Retrieval impreciso



Perguntas mal formuladas podem recuperar chunks irrelevantes, prejudicando a resposta final.

Não elimina alucinações



RAG reduz, mas não elimina completamente alucinações. O LLM ainda pode ignorar o contexto ou interpretá-lo errado.



RAG em Resumo

- ✓ LLMs são poderosos, mas têm data de corte e alucina
- ✓ RAG conecta o LLM a documentos externos em tempo real
- ✓ Fluxo: Pergunta → Retrieval → Contexto → Geração
- ✓ Reduz alucinações, mantém dados atualizados e privados
- ✓ Base para assistentes corporativos, chatbots e agentes de IA

"O futuro dos LLMs não é apenas geração — é geração fundamentada."

OBRIGADO