

LISTA 02 – Inteligência Artificial:

Felipe Rivetti Mizher – 821811

QUESTAO 1)

1 - Como uma árvore de decisão é gerada? Qual o significado do atributo que está na raiz da árvore?

Uma árvore de decisão é gerada a partir de um conjunto de dados, onde o algoritmo escolhe, em cada etapa, o atributo que melhor separa os dados. O atributo que está na raiz é o mais importante, pois é o que faz com que tenha a melhor divisão dos dados.

2 - Qual a diferença entre os nós internos e os nós de folha de uma árvore de decisão?

Um nó interno é um teste do valor de um dos atributos de entrada, já o nó folha é o valor a ser retornado.

3 - O que você pode fazer com uma árvore de decisão gerada a partir de uma base de dados?

Uma árvore de decisão pode ser usada para fazer previsões de qualquer exemplo de entrada. Ela ajuda a entender melhor os dados, porque mostra as decisões de acordo com as regras definidas.

4 - Quais as principais vantagens e desvantagens de um algoritmo de árvore de decisão?

Vantagens: Algumas das vantagens relacionadas a árvore de decisão é a flexibilidade, onde não assume nenhuma distribuição para os dados, seleção de atributos, que tenta manter contra a adição de atributos irrelevantes e a interpretabilidade, onde decisões complexas podem ser aproximadas por uma série de decisões mais simples.

Desvantagens: Precisa de mecanismos de fora para tratar valores faltantes, instabilidade, pois pequenas variações podem produzir grandes variações na árvore final e atributos contínuos que consomem muito tempo.

5 - Como avaliamos a qualidade de uma árvore?

Avaliamos uma árvore de decisão verificando a porcentagem de acerto, o erro e testando a árvore com dados que não foram usados nos dados de treinamento.

6 - Como podemos obter as regras a partir de uma árvore de decisão?

Podemos descobrir as regras de uma árvore seguindo da raiz até as folhas, onde cada caminho acaba formando uma nova regra de decisão formada por condições que leva até o resultado no nó folha.

QUESTAO 2)

1 - Calcule o ganho de informação para cada atributo. Qual será o atributo raiz da árvore?

O atributo raiz da árvore será o atributo Cliente.

2.1) CONCLUSÃO

1	→ SIM	1	1	1	1	1	1	$\frac{1}{9} = 0,5$
2	→ NÃO	2	2	2	2	2	2	$\frac{1}{9} = 0,5$

$$H = -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5)$$

$$H = -0,5 \cdot (-1) - 0,5 \cdot (-1)$$

$$H = 0,5 + 0,5$$

$$H = 1$$

ALTERNATIVO:

$$H(\text{ALTERNATIVO}) = \frac{6}{12} \cdot (1) + \frac{6}{12} \cdot (1)$$

$$H(\text{ALTERNATIVO}) = 1$$

$$\text{GAIN} = H(S) - H(\text{ALTERNATIVO})$$

$$G = 1 - 1 = 0$$

BAR:

$$H(\text{BAR}) = \frac{6}{12} \cdot (1) + \frac{6}{12} \cdot (1)$$

$$H(\text{BAR}) = 1$$

$$G = H(S) - H(\text{BAR})$$

$$G = 1 - 1$$

$$G = 0$$

SEX SAB:

$$P(\text{SIM}) = \frac{2}{5} = 0,4 \quad P(\text{NÃO}) = 0,6$$

$$P(\text{SIM}) = -0,4 \cdot \log(0,4) - 0,6 \cdot \log(0,6)$$

$$P(\text{SIM}) = 0,97$$

$$P(\text{NÃO}) = -0,57 \cdot \log(0,57) - 0,42 \cdot \log(0,42)$$

$$P(\text{NÃO}) = 0,98$$

$$H(\text{SEX SAB}) = \frac{5}{12} \cdot 0,97 + \frac{7}{12} \cdot 0,98$$

$$H(\text{SEX SAB}) = 0,99 + 0,56$$

$$H(\text{SEX SAB}) = 0,95$$

$$\text{GAIN} = H(S) - H(\text{SEX SAB})$$

$$\text{GAIN} = 1 - 0,95$$

$$\text{GAIN} = 0,05$$

FOME:

$$P(\text{sim}) = \frac{9}{12} = 0,75 \quad P(\text{nao}) = \frac{3}{12} = 0,25 \quad \left\{ \begin{array}{l} P(\text{sim}) = \frac{1}{5} = 0,2 \quad P(\text{nao}) = \frac{4}{5} = 0,8 \\ P(\text{sim}) = -0,21 \cdot \log(0,75) - 0,29 \cdot \log(0,25) \\ P(\text{sim}) = 0,95 \end{array} \right.$$

$$H(\text{FOME}) = \frac{9}{12} \cdot 0,95 + \frac{3}{12} \cdot 0,71$$

$$H(\text{FOME}) = 0,49 + 0,29$$

$$H(\text{FOME}) = 0,78$$

$$GAIN = H(S) - H(\text{FOME})$$

$$GAIN = 1 - 0,78$$

$$GAIN = 0,22$$

CLIENTES:

$$\text{NENHUM} = 0$$

$$\text{ALGUNS} = 0$$

CHGIO

$$P(\text{sim}) = \frac{2}{6} = 0,33 \quad P(\text{nao}) = \frac{4}{6} = 0,67$$

$$P(\text{CHGIO}) = -0,33 \cdot \log(0,33) - 0,67 \cdot \log(0,67)$$

$$P(\text{CHGIO}) = 0,90$$

$$H(\text{CLIENTE}) = \frac{2}{12} \cdot 0 + \frac{4}{12} \cdot 0 + \frac{6}{12} \cdot 0,90$$

$$GAIN = 1 - 0,45$$

$$H(\text{CLIENTE}) = 0,45$$

$$GAIN = 0,55$$

PREÇO:

$$R: P(\text{sim}) = \frac{7}{12} = 0,58 \quad P(\text{nao}) = \frac{5}{12} = 0,42 \quad \left\{ \begin{array}{l} \text{RRR: } P(\text{sim}) = \frac{1}{3} = 0,33 \quad P(\text{nao}) = \frac{2}{3} = 0,66 \\ P(R) = -0,58 \cdot \log(0,58) - 0,42 \cdot \log(0,42) \\ P(R) = 0,98 \end{array} \right.$$

$$P(R) = -0,58 \cdot \log(0,58) - 0,42 \cdot \log(0,42)$$

$$P(R) = 0,98$$

$$P(\text{RRR}) = -0,33 \cdot \log(0,33) - 0,66 \cdot \log(0,66)$$

$$P(\text{RRR}) = -0,33 \cdot (-1,60) - 0,66 \cdot (-0,59)$$

$$P(\text{RRR}) = 0,59 + 0,39$$

$$P(\text{RRR}) = 0,9$$

$$RR: 0$$

$$H(\text{PREÇO}) = \frac{7}{12} \cdot 0,98 + \frac{5}{12} \cdot 0,9$$

$$GAIN = 1 - 0,79$$

$$H(\text{PREÇO}) = 0,96 + 0,22$$

$$GAIN = 0,22$$

$$H(\text{PREÇO}) = 0,78$$

CHUVA:

$$\begin{aligned} P(\text{sim}) &= \frac{3}{5} = 0,6 & P(\text{NÃO}) &= \frac{2}{5} = 0,4 & \left\{ \begin{aligned} P(\text{sim}) &= \frac{3}{7} = 0,42 & P(\text{NÃO}) &= \frac{4}{7} = 0,57 \\ P(\text{sim}) &= -0,6 \cdot \log(0,6) - 0,4 \cdot \log(0,4) & P(\text{NÃO}) &= -0,42 \cdot \log(0,42) - 0,57 \cdot \log(0,57) \\ P(\text{sim}) &= 0,97 & P(\text{NÃO}) &= 0,97 \end{aligned} \right. \end{aligned}$$

$$H(\text{CHUVA}) = \frac{5}{12} \cdot 0,97 + \frac{7}{12} \cdot 0,97 \quad \left\{ \begin{aligned} \text{GAIN} &= 1 - 0,95 \\ \text{GAIN} &= 0,05 \end{aligned} \right.$$

$$H(\text{CHUVA}) = 0,99 + 0,56$$

$$H(\text{CHUVA}) = 0,95$$

RES:

$$\begin{aligned} P(\text{sim}) &= \frac{3}{5} = 0,6 & P(\text{NÃO}) &= \frac{2}{5} = 0,4 & \left\{ \begin{aligned} P(\text{sim}) &= \frac{3}{7} = 0,42 & P(\text{NÃO}) &= \frac{4}{7} = 0,57 \\ P(\text{sim}) &= -0,6 \cdot \log(0,6) - 0,4 \cdot \log(0,4) & P(\text{NÃO}) &= -0,42 \cdot \log(0,42) - 0,57 \cdot \log(0,57) \\ P(\text{sim}) &= 0,97 & P(\text{NÃO}) &= 0,97 \end{aligned} \right. \end{aligned}$$

$$H(\text{RES}) = \frac{5}{12} \cdot 0,97 + \frac{7}{12} \cdot 0,97 \quad \left\{ \begin{aligned} \text{GAIN} &= 1 - 0,95 \\ \text{GAIN} &= 0,05 \end{aligned} \right.$$

$$H(\text{RES}) = 0,95$$

TiPO:

FRANCESA:

$$\begin{aligned} P(\text{sim}) &= \frac{1}{2} = 0,5 & P(\text{NÃO}) &= \frac{1}{2} = 0,5 & \left\{ \begin{aligned} P(\text{sim}) &= \frac{1}{4} = 0,5 & P(\text{NÃO}) &= \frac{3}{4} = 0,5 \\ P(\text{FRAN}) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) & P(\text{TAI}) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) \\ P(\text{FRAN}) &= 0,5 + 0,5 = 1 & P(\text{TAI}) &= 0,5 + 0,5 = 1 \end{aligned} \right. \end{aligned}$$

HAMBURGUEZ:

$$\begin{aligned} P(\text{sim}) &= \frac{2}{4} = 0,5 & P(\text{NÃO}) &= \frac{2}{4} = 0,5 & \left\{ \begin{aligned} P(\text{sim}) &= \frac{1}{2} = 0,5 & P(\text{NÃO}) &= \frac{1}{2} = 0,5 \\ P(\text{HAM}) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) & P(\text{ITA}) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) \\ P(\text{HAM}) &= 0,5 + 0,5 = 1 & P(\text{ITA}) &= 1 \end{aligned} \right. \end{aligned}$$

$$H(\text{TiPO}) = \frac{2}{12} \cdot 1 + \frac{5}{12} \cdot 1 + \frac{4}{12} \cdot 1 + \frac{2}{12} \cdot 1$$



$$H(\text{TiPO}) = 1$$

$$\text{GAIN} = 1 - 1$$

$$\text{GAIN} = 0$$

TEMPO:

$$\begin{aligned} 0-10: & \left\{ \begin{aligned} P(\text{sim}) &= \frac{4}{6} = 0,66 & P(\text{NÃO}) &= \frac{2}{6} = 0,33 \\ P(0-10) &= -0,66 \cdot \log(0,66) - 0,33 \cdot \log(0,33) & P(10-20) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) \\ P(0-10) &= 0,35 + 0,52 = 0,90 & P(10-20) &= 0,5 + 0,5 = 1 \end{aligned} \right. \end{aligned}$$

20-30:

$$\begin{aligned} P(\text{sim}) &= \frac{1}{2} = 0,5 & P(\text{NÃO}) &= \frac{1}{2} = 0,5 & \left\{ \begin{aligned} P(\text{sim}) &= \frac{0}{2} = 0 & P(\text{NÃO}) &= \frac{2}{2} = 1 \\ P(20-30) &= -0,5 \cdot \log(0,5) - 0,5 \cdot \log(0,5) & P(20-30) &= 0 \\ P(20-30) &= 0,5 + 0,5 = 1 \end{aligned} \right. \end{aligned}$$

$$H(\text{TEMPO}) = \frac{6}{12} \cdot 0,9 + \frac{2}{12} \cdot 1 + \frac{2}{12} \cdot 1 + \frac{2}{12} \cdot 0$$

$$H(\text{TEMPO}) = 0,45 + 0,16 + 0,16 + 0$$

$$H(\text{TEMPO}) = 0,77$$

$$\text{GAIN} = 1 - 0,77$$

$$\text{GAIN} = 0,23$$

2 - Qual atributo estará no segundo nível da árvore? Faça os cálculos e apresente a árvore gerada até o segundo nível.

RAIZ -> Cliente

-> Nenhum = NÃO

-> Alguns = SIM

-> Cheio -> FOME()

QUESTAO 3)

1 - Quais as diferenças entre os algoritmos de árvore ID3 e C4.5?

O C4.5 foi desenvolvido para ser uma extensão do ID3, onde foram feitas melhorias, de forma que anulassem as desvantagens do ID3. Algumas melhorias como, lidar melhor com dados contínuos, retroceder pela árvore quando ela é criada para tentar remover ramificações que não ajudam no processo de decisão, a poda da árvore, e implementar a razão de ganho, e não o ganho de informação igual ao do ID3.

2 - Como o algoritmo C4.5 lida com os atributos de entrada que são numéricos?

O C4.5 trata os dados contínuos calculando os pontos médios entre os dados, ordenando os dados e calculando pontos de divisão candidatos. Para cada ponto de corte, ele calcula o ganho de informação para melhor dividir os grupos.

QUESTAO 4)

1 - Com base nestas informações, quais serão as saídas da árvore (classes preditas) para os seguintes registros de teste?

- A) Iris-versicolor
- B) Iris-setosa
- C) Iris-virginica
- D) Iris-virginica

QUESTAO 5)

Considere a seguinte matriz de confusão obtida para o problema do restaurante (i.e., o objetivo era decidir se espero uma mesa em um restaurante) por meio de uma Árvore de Decisão:

		Classe Predita	
		SIM	NÃO
Classe Verdadeira	Vou esperar?		
	SIM	15	3
	NÃO	5	10

Quais são os valores das métricas abaixo para cada uma das classes (SIM/NÃO)

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
Sim	0,83	0,16	0,25	0,66	0,76	0,83	0,78
Não	0,66	0,33	0,75	0,83	0,46	0,66	0,71

QUESTAO 6)

Considere agora uma matriz de confusão obtida por meio de uma Árvore de Decisão para um problema genérico de classificação de quatro classes:

		Classe Predita			
		A	B	C	C
Classe Verdadeira	A	10	4	2	1
	B	1	15	2	0
	C	2	3	20	5
	D	4	1	2	50

Quais são os valores das métricas abaixo para cada uma das classes A, B, C e D?

	TVP	TFN	TFP	TVN	Precisão	Recall	F1-Score
A	0,58	0,41	0,06	0,93	0,90	0,57	0,58
B	0,83	0,16	0,07	0,92	0,92	0,83	0,73
C	0,66	0,33	0,06	0,93	0,91	0,66	0,71
D	0,87	0,12	0,09	0,90	0,90	0,87	0,88