

LISTA 03 – Inteligência Artificial:

Felipe Rivetti Mizher – 821811

QUESTAO 1)

1 - Qual a importância de separar um conjunto de dados em conjuntos de treinamento e de teste?

A importância é para que possa treinar o modelo com uma parte dos dados, e com a outra parte possa fazer uma avaliação com teste que o modelo nunca tinha visto, diferente do treinamento.

2 - Qual a principal limitação do método holdout em relação à partição dos dados e de que forma a Amostragem Aleatória busca mitigar esse problema?

A principal limitação é que depende de como os dados são divididos, pois pode acontecer dos exemplos mais fáceis caírem no subconjunto de testes.

3 - Em um cenário de 5-fold cross-validation (validação cruzada), qual a porcentagem média de exemplos compartilhados entre os diferentes subconjuntos de treinamento?

Para um cenário de 5-fold a porcentagem será de 80% dos dados compartilhados entre os subconjuntos.

4 - Qual a principal diferença entre os métodos de Amostragem Aleatória e Bootstrap?

A principal diferença entre os dois modos, é que a Amostragem não utiliza a reposição, e já o Bootstrap utiliza a reposição.

5 - Em métodos de aprendizado de máquina, qual a diferença entre as definições de “parâmetros” e “hiperparâmetros”? Cite exemplos no contexto de árvores de decisão.

Os parâmetros são aprendidos automaticamente pelo sistema, já os hiperparâmetros são definidos pelo cientista de dados antes do início dos testes.

No contexto de uma árvore, os parâmetros podem ser ditos como os nós, de decisão e o hiperparâmetro pode ser dito como os critérios de divisão para os elementos da árvore.

6 - Qual a importância de um conjunto de validação distinto do conjunto de teste final?

É importante ter esses dois conjuntos separados pois o conjunto de validação serve para ajustar o modelo, e o conjunto de teste final serve apenas para a uma avaliação. Ter esses dois separados ajuda a evitar o overfitting e ajuda também a ter uma estimativa mais confiável do desempenho.

QUESTAO 2)

1 - Uma pessoa cientista de dados treinou um modelo de classificação utilizando ressubstituição para avaliação e obteve acurácia de 100%. Entretanto, ao aplicar o modelo em novos dados, a acurácia caiu para 62%. Explique por que isso ocorreu e proponha uma estratégia de avaliação mais adequada.

Isso ocorreu pois como o conjunto de treinamento é o mesmo do conjunto de teste, o modelo não aprendeu todas as regras possíveis e quando foi submetido a um novo conjunto de dados, a acurácia acabou caindo para 62%.

Uma solução para tentar resolver, é não ter exemplos em comum no conjunto de teste e no de treinamento.

QUESTAO 3)

1 - Considere um modelo avaliado por 10-fold cross validation. Se o conjunto de dados possui 200 exemplos, quantos exemplos são usados para teste em cada iteração?

Serão usados 20 exemplos para teste em cada iteração.

QUESTAO 4)

1 - Explique a razão pela qual métodos ensemble tendem a apresentar melhor desempenho do que classificadores individuais.

O método ensemble tende a mostrar melhor desempenho por combinar múltiplos modelos individuais, reduzindo os erros de cada um. Fazendo assim, ao utilizar vários modelos, o ensemble consegue produzir resultados mais precisos e melhores do que um único classificador.

2 - Quais os principais tipos de métodos ensemble e qual a principal diferença entre eles?

Os principais são Bagging, Boosting e Stacking. A principal diferença entre eles é o modo como são combinados. O **Bagging** treina o modelo de forma independente, o **Boosting** treina o modelo de forma sequencial e já o **Stacking** combina diferentes formas para gerar a predição final.

3 - Como o algoritmo Random Forest garante que as árvores criadas sejam diferentes entre si, além do uso de Bootstrap?

O Random Forest garante que será diferente pois ele cria as árvores selecionando aleatoriamente os subconjuntos de atributos em cada divisão. Fazendo assim com que as características para tomar as decisões sejam diferentes entre si.

QUESTAO 5)

1 - Em um ensemble baseado em bagging, dez classificadores retornaram as seguintes previsões:

Classificador	Previsão
C1	Positivo
C2	Positivo
C3	Negativo
C4	Positivo
C5	Negativo
C6	Negativo
C7	Positivo
C8	Negativo
C9	Negativo
C10	Negativo

Qual será a predição final? Justifique sua resposta.

Como o Bagging é escolhido pela maioria, temos 4 positivos e 6 negativos. Então a predição final será negativa.

QUESTAO 6)

1 - Por que o classificador Naive Bayes é chamado de “ingênuo”? Explique a suposição de independência e discuta se ela é realista em problemas do mundo real.

Ele é considerado ingênuo pois faz suposições relacionadas aos atributos, fazendo com que os cálculos sejam simplificados. Essa suposição apesar de simplificar o cálculo geralmente não é a realidade em problemas do mundo real. Ainda assim apresenta bom desempenho na prática.

2 - Como o Naive Bayes lida com atributos numéricos (contínuos) em comparação com atributos categóricos?

Os atributos categóricos utilizam a probabilidade baseada em frequência, já os atributos numéricos utilizam a probabilidade de distribuição utilizando a média e o desvio padrão para serem calculados.

QUESTAO 7)

1 - Uma loja de eletrônicos deseja prever se um cliente comprará um produto com base em sua idade, renda e se é estudante ou não. O histórico de clientes desta loja é dado pela tabela:

Cliente	Idade	Renda	Estudante	Compra
c1	Jovem	Alta	Não	Não
c2	Jovem	Alta	Não	Não
c3	Meia-idade	Alta	Não	Sim
c4	Idoso	Média	Não	Sim
c5	Idoso	Baixa	Sim	Sim
c6	Idoso	Baixa	Sim	Não
c7	Meia-idade	Baixa	Sim	Sim
c8	Jovem	Média	Não	Não
c9	Jovem	Baixa	Sim	Sim
c10	Idoso	Média	Sim	Sim

Dado um novo cliente que é jovem, tem renda média e é estudante, qual será a predição realizada por um classificador Naive Bayes? Mostre os cálculos das probabilidades e indique a classe final.

7. $C(\text{Sim}) = 6/10 = 0,6$
 $C(\text{Não}) = 4/10 = 0,4$

• SIM • NÃO

$P(\text{Jovem} | \text{Sim}) = 1/6$ $P(\text{Jovem} | \text{Não}) = 3/4$
 $P(\text{Média} | \text{Sim}) = 2/6$ $P(\text{Média} | \text{Não}) = 1/4$
 $P(\text{Estu. Sim} | \text{Sim}) = 4/6$ $P(\text{Estu. Não} | \text{Não}) = 1/4$

$P(\text{Sim}) = \frac{6}{10} \cdot \frac{1}{6} \cdot \frac{2}{6} \cdot \frac{4}{6}$ $P(\text{Não}) = \frac{4}{10} \cdot \frac{3}{4} \cdot \frac{1}{4} \cdot \frac{1}{4}$

$P(\text{Sim}) = \frac{44}{2160} \approx 0,0222$ $P(\text{Não}) = \frac{36}{640} \approx 0,0562$

A predição final para os parâmetros passados será "NÃO".